

7 大 AI 启动包 · 第 03 个



《AI口播短视频》启动包

8 分镜短视频 · B-roll · AI 剪辑

SUMA College 【AI 内容营销系统 + 线下实操课】 · 报名即送 7 大 AI 启动包 (总价值 RM5,500)

Skill · AI 影片（工具：Higgsfield / Seedance）

在系统里的工位：把脚本变成完整口播短视频——视频生产线的核心（数字人见 7大AI启动包/05-《AI数字分身》启动包，音乐见 7大AI启动包/07-《AI品牌配乐》启动包）。

- 先分两条路线（跟院长 slide 一致，脚本角度完全不同）：
 - 个人 IP / AI 数字人口播：你（或数字分身）出镜讲观点/方法，建立个人影响力——台词是「你的主张」，靠持续 + 独特观点。
 - 卖产品 / 服务影片广告：推货/服务成交——台词是「痛点→产品价值→证据→CTA」，B-roll show 产品/成品/使用场景。

流水线

分镜脚本（进表）→ 锁人物（多张脸参考）→ seedance 逐镜生成 → 抽帧验证 → 拼接完整版

1. 分镜脚本进表格（一 shot 一行）：镜号/类型 · Prompt · 台词 · 平台。整支约 60—100s。列宽示例 199 / 562 / 290 / 120（Prompt 列最宽）。
2. 锁人物（口播镜）：用 3 张真人脸参考图（正脸+不同角度更稳）当 `image_references`，每个真人镜 prompt 重复完整 persona 描述 → 全片同一个人。
3. 逐镜生成：`seedance_2_0` · 9:16 · 每镜 4—15s。
4. 验证 + 拼接：抽帧检查（无 ffmpeg 用 `imageio_ffmpeg`）→ 统一参数 → concat 完整版。

● 硬规则（实操固化，最重要）

1. 强制无字幕（最容易踩）

- 原生配音（`generate_audio=true`）默认会把台词烤成字幕，模型不会自己去掉。
- prompt 写死这句（漏了就有字幕，写了就干净——已验证）：

> ABSOLUTELY NO on-screen text, NO subtitles, NO captions, NO burned-in words of ANY kind anywhere in the frame – completely clean footage, all text added later in post.

- 品牌名 / CTA / 字幕 全部后期（CapCut/Canva）加，AI 生成保持干净无字。

2. 真人感：照片级真人 + 会眨眼 + 眼珠会动（否则「卡通脸 / 木偶死眼」）

- ● 数字人必须「照片级真人」（不是卡通、不是 3D avatar）：prompt 写死

> PHOTOREAL, REALISTIC HUMAN presenter talking to camera, a real-looking person, natural skin, NOT a cartoon, NOT a 3D avatar, NOT CGI.

漏了这条第一版就会出卡通/塑料脸（详见 7大AI启动包/05-《AI数字分身》启动包）。

- prompt 再写活人细节：

> BLINKS naturally, EYES alive with the eyeballs MOVING via subtle micro-saccades, gaze shifts naturally, small head/eyebrow micro-movements, gentle breathing – a real living human, NOT a staring mannequin with dead eyes.

- 静态参考图 + 没写眼动 → 模型只动嘴、眼睛发呆。

3. 运镜 / 动作 (1-3 镜点缀, 避免死机位)

- 推镜 `SLOW CINEMATIC CAMERA PUSH-IN` (hook / CTA 收尾) · 横摇 `CAMERA SLOWLY PANS` (展示一排东西) · 手持 `slight handheld camera movement` (口语段) · 动作: 手势 / 前倾 / 指向。别每镜都加。

4. B-roll = 无脸真实近景, 对应台词点名的东西

- 📌 **首选: 无脸真实近景 (close-up) 实拍/录屏, show 那句台词点名的东西本身** (工具/产品/成品/流程)。真实、贴题。
- 📌 **优先用你自己的真实素材**: 开工前把该工具/产品/成品的真实截图或短片发给 Claude → 当 `image_references` 或让它照着写 prompt, B-roll 才贴、才真、**不乱造假界面**。没参考时才让它按台词描述生成近景示范。
- 📌 **B-roll 一律不放主播、不需要口型** → 生成时 `generate_audio=false` 且不给 `audio_references` → 无口型问题、几乎不烤字幕。
- ❌ **别让主播出境做演示镜**: 主播一开口就要对口型, 而 `audio_ref` 口型在演示镜上不稳、还随机烤字幕。口播归口播、演示归无脸 B-roll, 分开最稳。
- 📌 **B-roll 必须跟那句台词内容对应** (讲 A 就 show A), 泛泛「人在打电脑」不算。
- 📌 **画面要快切**: prompt 写 `FAST-PACED, snappy quick HARD CUTS every ~1.2-1.5s, everything moving fast, no slow lingering shots`。
- 📌 **prompt 绝不写 hex 色号 / 文字标签** (会被烤成乱码文字, 跟海报「别写字体规格」同一个坑); 改写方向词 (如 `blue-and-white palette`) + **纯图标/纯抽象**, 并加死 `NO letters, NO numbers, NO words, NO labels of ANY kind`。
- 屏幕内容一律 **soft/out of focus, 无可读文字**。

4.5 口型对齐 + 声音一致 (真人口播镜正解)

要「同一把声音 + 无字幕 + 口型准」三者都满足 → 走「静音生成 + 合声」, 别用原生:

1. **选声** (见 §5) → 拿到 `voice_id`。
2. **逐句 TTS** (`seed_audio` ; `speech_rate` 用整数, 正=快) → 每句 wav + 时长。
3. **静音生成视频** (`generate_audio=false` + `audio_references=<该句TTS>` + 脸参考), `duration = round(音频秒数)` (📌 **别 ceil!** ceil 会把嘴型摊长、越到后面越拖——实测音频 12.23s 设 13 就飘, 设 12 就准)。
4. **PTS 精确合声**: 视频与音频差零点几秒时, mux 把视频 `setpts` 拉/缩到音频时长再贴, 端到端不漂、不丢词。

⚠️ 原生 `generate_audio=true` 会烤字幕、且每镜声音会飘, 无字幕护栏也不 100% 可靠。要口型紧可用它, 但要**无字幕+同声就不能用** → 真人镜一律走上面的「静音+合声」。
`voice_change` (换音色保时序) 只在**源视频已无字幕**时才有用。

5. 选声 (按数字人性别)

- **默认走 preset, 按数字人性别挑**: 男→男声、女→女声。 `list_voices` 看全部 (男/女各约 20 把) + `preview_url` 试听; 用 `voice_type='preset'` + `voice_id`。
- **想更像某个真人本尊** → 才克隆 (`create_voice_from_confirmed_audio` , 干净样本: 安静、近麦 ~15cm、无背景乐、连续讲 ~1 分钟; 样本脏 → 克隆薄+带杂音)。
- ⚠️ preset 偏英语训练, **中文/其他语口播可能带点口音**; 在意腔调就试听后定, 或用克隆。
- B-roll 旁白用同一把声保持一致。

6. 台词

- 用你目标市场的语言/口语、无口头禅；要多要实；从第一帧就讲、不留白；语速偏快不拖。

7. 背景

- 背景虚化、无可读文字（`background softly out of focus, NO readable text`）——否则参考图里的字会被带进画面。

8. 合规红线

- 按你自己行业/品牌的合规红线走（该写什么、绝不写什么）。
- 人物贴你的目标市场（含背景/屏幕里的人）。

参数 & 成本（省 credit）

- 一律 480p + `mode fast`（≈15—18 credit/镜）；实测 `std/720p` 没明显差别、不值 3—4 倍。
- `count=1`，一镜一条。
- 弹 `preset` 推荐不想用 → 带 `declined_preset_id` 原样重发。
- 先验 1 镜确认「声音+无字幕+眨眼+脸」→ OK 再批量。

AI 剪片（字幕 / 配乐 / 音效 —— 不用 CapCut 也能做不少）

生成 + 拼接之后的剪辑，Claude + ffmpeg 现在就能做：

- 上字幕（自动）：台词和 TTS 时间我们本来就有 → Claude 按时间生成 `.srt / .ass`（带样式：字体/描边/位置），ffmpeg 烧进画面：`ffmpeg -i v.mp4 -vf "subtitles=sub.ass" out.mp4`。不用手动 CapCut 打字。

- 配乐：Suno 背景乐 ffmpeg 垫底轨、音量压低（见 7大AI启动包/07-《AI品牌配乐》启动包）。
- 音效：在时间点混 SFX（转场声/点击声）→ ffmpeg `adelay` + `amix`。
- 基础特效/转场：淡入淡出、缩放推拉、文字动画（ffmpeg `fade` / `zoompan` / `drawtext`）。
- 复杂特效/花哨转场（花字、贴纸、节奏卡点）→ 用下面的 HyperFrames，或剪辑/CapCut。

🔥 AI 剪辑进阶：HyperFrames（写 HTML → 渲染视频 · 免费商用 · 实测可用）

CapCut 那种「动态字幕 / 花字 / 下三分标 / 卡点」，现在能用代码做——而且是 AI agent 直接帮你写。这是「一直人头、没包装」这个缺口的真解。

它是什么：HeyGen 开源的框架（[Apache-2.0](#)，[免费商用](#)），把 HTML/CSS/动画渲染成确定性的 MP4（同样输入 → 同样结果，可重跑、可参数化批量出片）。自带 20 个 skills 给 Claude Code 用。

装（一次过）：

```
npx skills add heygen-com/hyperframes --all --full-depth --yes # 20
brew install ffmpeg # 必
npx hyperframes doctor # 1
```

对着现成口播片，最常用这三个（先读路由 `/hyperframes`，它会帮你选）：

skill	干什么
/talking-head-recut	给人头片加动态标题 / 下三分标 / 数据 callout / 引言卡 / 画中画 —— 治「一直人头」
/embedded-captions	只加字幕（原片不动），主体还能挡住字幕（有层次）
/motion-graphics	单独做 10 秒内的动态图形 / logo sting / 透明下三分标（可叠进剪映）

● 中文三大坑（实测踩过，照抄解法就好）

- 1. 自带字体没有中文 —— 它 bundle 的 6 个字体全是 latin 子集（LXGWenKaiTC-400-latin.woff2 才 19KB，真中文字体是 5-20MB）。直接用 → 中文全变豆腐块 □□□。

→ 解法：自己放一个中文字体（Noto Sans SC，开源 OFL 可商用）进 public/fonts/，用 @font-face 引用。别只写 font-family，它的静态分析器不认。

- 1. Whisper 默认模型是纯英文 —— tiny.en / small.en / medium.en 全带 .en。

→ 中文必须 --model large-v3 --language zh（多语言的只有 large-v3，约 3GB，第一次会自动下）。

- 1. 中文没空格 → word 级时间码直接躺平 —— whisper-cpp 会把 84 秒整段吐成一个 word（0.32 → 84.04），卡片定时全废。

→ 解法：如果你的片是分镜拼的，用 ffmpeg 检测硬切点拿真实分段，再套你自己的脚本文字（比 ASR 还准、零错字）：

```bash

```
ffmpeg -i in.mp4 -filter:v "select='gt(scene,0.3)',showinfo" -f null - 2>&1 | grep -oE "pts_time:[0-9.]+"
...
```

✅ 校验法：每段「字数 ÷ 秒数」应稳定在 ~6 字/秒；某段偏太多 = 那个切点抓错了（B-roll 的横摇/动画会产生假切点，要剔除）。

它不干事（别指望）：不改原片本身 —— 重新剪节奏、换背景、调色、改音频 = NLE 剪辑，超出它范围。原片在底下完整播，它只在上面叠设计好的图层。

其他两条路（实测结论，别浪费时间）

- Remotion（用 React 写视频）：能力相当、中文渲染同样干净。⚠️ 但 >3 人的营利公司商用要买 Company License（remotion.pro）；个人 / ≤3 人公司 / 非营利 / 评估期免费。你是小团队就能白嫖。
- Gemini Omni（Google）：能生成视频、也能「附参考片 + 原片」做风格迁移。实测：效果不稳、不好用，中文字幕也烧不干净。当玩具行，别当生产工具。

接进系统

- 成品贴回你的内容表 + 归档：[Stage]/[受众]/Video 素材/[命名]/[分镜 + 完整版]。
- 拼接：imageio\_ffmpeg concat；字幕/配乐用上面「AI 剪片」；花哨特效后期加。

📎 SUMA 内部示例（仅供参考，不是通用规则）：主播 Jared + 极致鸭噪克隆声；B-roll = 6 个 AI 工具逐个近景示范（写文案屏/出图/数字人/PPT/波形/剪辑）；合规

红线 = 不写价格/免费/具体名额数字（用「名额有限」）、完整品牌名、人物一律马来西亚本地人。换成你自己行业的即可。